Нормализация признаков

Данное задание основано на материалах лекции по линейным методам классификации.

Вы научитесь:

- работать с персептроном простейшим вариантом линейного классификатора
- повышать качество линейной модели путем нормализации признаков

Введение

Линейные алгоритмы — распространенный класс моделей, которые отличается своей простотой и скоростью работы. Их можно обучать за разумное время на очень больших объемах данных, и при этом они могут работать с любыми типами признаков — вещественными, категориальными, разреженными. В этом задании мы предлагаем вам воспользоваться персептроном — одним из простейших вариантов линейных моделей.

Как и в случае с метрическими методами, качество линейных алгоритмов зависит от некоторых свойств данных. В частности, признаки должны нормализованы, то есть иметь одинаковый масштаб. Если это не так, и масштаб одного признака сильно превосходит масштаб других, то качество может резко упасть.

Один из способов нормализации заключается в стандартизации признаков. Для этого берется набор значений признака на всех объектах, вычисляется их среднее значение и стандартное отклонение. После этого из всех значений признака вычитается среднее, и затем полученная разность делится на стандартное отклонение.

Реализация в Scikit-Learn

В библиотеке scikit-learn линейные методы реализованы в пакете sklearn.linear_model. Мы будем работать с реализацией персептрона sklearn.linear_model.Perceptron. Как и у большинства моделей, обучение производится с помощью функции fit, построение прогнозов — с помощью функции predict.

Пример использования:

```
import numpy as np
from sklearn.linear_model import Perceptron
X = np.array([[1, 2], [3, 4], [5, 6]])
y = np.array([0, 1, 0])
clf = Perceptron()
clf.fit(X, y)
predictions = clf.predict(X)
```

В качестве метрики качества мы будем использовать долю верных ответов (accuracy). Для ее подсчета можно воспользоваться функцией sklearn.metrics.accuracy_score, первым аргументом которой является вектор правильных ответов, а вторым — вектор ответов алгоритма.

Для стандартизации признаков удобно воспользоваться классом sklearn.preprocessing.St Пример использования:

```
\begin{array}{lll} & \textbf{from} & \textbf{sklearn.preprocessing} & \textbf{import} & \textbf{StandardScaler} \\ \textbf{scaler} & = & \textbf{StandardScaler()} \\ \textbf{X\_train} & = & \textbf{np.array} \left( \left[ \left[ 100.0 \, , \, 2.0 \right] \, , \, \left[ 50.0 \, , \, 4.0 \right] \, , \, \left[ 70.0 \, , \, \, 6.0 \right] \right] \right) \\ \textbf{X\_test} & = & \textbf{np.array} \left( \left[ \left[ 90.0 \, , \, 1 \right] \, , \, \left[ 40.0 \, , \, 3 \right] \, , \, \left[ 60.0 \, , \, \, 4 \right] \right] \right) \\ \textbf{X\_train\_scaled} & = & \textbf{scaler.fit\_transform} \left( \textbf{X\_train} \right) \\ \textbf{X\_test\_scaled} & = & \textbf{scaler.transform} \left( \textbf{X\_test} \right) \end{array}
```

Инструкция по выполнению

- 1. Загрузите обучающую и тестовую выборки из файлов perceptrontrain.csv и perceptron-test.csv. Целевая переменная записана в первом столбце, признаки — во втором и третьем.
- 2. Обучите персептрон со стандартными параметрами и random state=241.
- 3. Подсчитайте качество (долю правильно классифицированных объектов, ассигасу) полученного классификатора на тестовой выборке.

- 4. Нормализуйте обучающую и тестовую выборку с помощью класса StandardScaler.
- 5. Обучите персептрон на новых выборках. Найдите долю правильных ответов на тестовой выборке.
- 6. Найдите разность между качеством на тестовой выборке после нормализации и качеством до нее. Это число и будет ответом на задание.

Если ответом является нецелое число, то целую и дробную часть необходимо разграничивать точкой, например, 0.421. При необходимости округляйте дробную часть до трех знаков.

Ответ на каждое задание — текстовый файл, содержащий ответ в первой строчке. Обратите внимание, что отправляемые файлы не должны содержать перевод строки в конце. Данный нюанс является ограничением платформы Coursera. Мы работаем над тем, чтобы убрать это ограничение.